

PROGNOSE DER KAUFABSICHT IM E-COMMERCE

Online Shoppers Purchasing Intention - Data Analyst IHK

Gruppenprojekt | Juni 2026

Ausgearbeitet von:

Marzieh Vatandoostkamali

Nataliia Melnytska


Annick Constance Demgne Tchuenkam

Hiba Ben Rhouma

Revenue
TRUE/FALSE

AGENDA

Vom Business-Problem bis zum verwertbaren Marketing-Output



Leitfrage

Die Kernfrage lautet: Welche Verhaltenssignale einer Web-Session lassen eine Kaufabsicht (Revenue = TRUE) erkennen?

Präsentationslogik


Business-Frage in messbare ML-Aufgabe übersetzen
EDA-Ergebnisse als Grundlage für Hypothesen nutzen
Modelle vergleichen und Random Forest begründen
Zielgruppen exportieren und Handlungsempfehlungen ableiten

**Revenue
TRUE/FALSE**

AUSGANGSSITUATION: GERINGE CONVERSION, HOHER OPTIMIERUNGSBEDARF

Klassifikationsziel: Revenue = TRUE/FALSE

Revenueverteilung



12.330

abgeschlossene
Web-Sessions

15,5 %

Kaufsessions
(Revenue=TRUE)

18

Attribute: Verhalten,
Situation, Technik

84,5 %

Sessions ohne
Kaufabschluss

Business-Relevanz

Kaufabbrüche enthalten Marketing-Potenzial
Frühe Erkennung ermöglicht gezieltes Retargeting
ML unterstützt Priorisierung statt Bauchgefühl

USER STORIES-SPRINT1

Fokus auf Vorhersage, Segmentierung und erklärbare Einflussfaktoren

US-01 Kaufwahrscheinlichkeit vorhersagen

E-Commerce-Manager

Steigerung der Conversion Rate
weniger Streuverluste
Höhere Umsatzchancen

US-02 Retargeting-Zielgruppen exportieren

Marketing-Spezialistin

ROI von Google- und Meta-Ads
Kampagne
Ansprache einer kaufnahen
Nutzergruppe im Retargeting


US-05 Einflussfaktoren identifizieren

Data Scientist

Optimierte Nutzerführung auf der
Website

Wie können wir durch Datenanalyse und Machine Learning diese Herausforderungen nicht nur verstehen, sondern auch konkret in Lösungen umsetzen?

EDA: WELCHE SIGNALE ZEIGEN KAUFABSICHT?



EDA übersetzt Rohdaten in erste Business-Erkenntnisse:

- Welche Verhaltensmuster unterscheiden Käufer von Nicht-Käufern?
- Gibt es erkennbare Signale, bevor ein Kauf abgeschlossen wird?

EDA: KÄUFER VERHALTEN SICH ANDERS

Käufer verhalten sich deutlich anders als Nicht-Käufer

Verhaltensunterschiede zwischen Käufer und Nicht-Käufer

Merkmal	Kein Kauf	Kauf	Faktor
PageValues (Ø)	1,98	27,26	13,8x
ProductRelated (Ø)	28,7	48,2	1,7x
BounceRates (Ø)	2,5 %	0,5 %	0,2x
ExitRates (Ø)	4,7 %	2,0 %	0,4x
Produktdauer (Ø)	1.070 s	1.876 s	1,8x

**Der Kauf passiert nicht zufällig,
er kündigt sich im Verhalten der
Session an:**

Käufer sehen sich mehr Produktseiten
an, verweilen länger auf den


Produktseiten

→ höhere PageValues

springen seltener ab


→ geringere Absprung-/Austrittsraten.

EDA: HYPOTHESEN HÄNGT AUCH VOM KONTEXT AB



- Höchste Anzahl an Käufen im November (760 Sessions)
- Im Mai wurde das höchste Besucheraufkommen registriert (3364 Sessions) weist nicht die höchste Anzahl an Käufen auf


→ Entscheidend ist die Qualität des Traffics und die Kaufabsicht der Besucher.



New Visitors: höchste Kaufquote - 24,9 %
Returning Visitors: niedrigste Kaufquote (13,9 %)

→ Der Besuchertyp könnte die Kaufwahrscheinlichkeit beeinflussen.

EDA: ABBRUCHSIGNALLE: BOUNCE RATES UND EXIT RATES



Besucher, die früh abspringen oder den Kaufprozess vorzeitig verlassen, kaufen deutlich seltener.

HYPOTHESENPRÜFUNG


EDA-Ergebnisse werden in prüfbare Aussagen übersetzt

Hypothese	Begründung	Ergebnis
H1: PageValues erhöhen Kaufwahrscheinlichkeit	Käufer weisen deutlich höhere PageValues auf; stärkster Zusammenhang mit Revenue.	Bestätigt
H2 : Besuchertyp beeinflusst Kaufwahrscheinlichkeit	Die Kaufquote unterscheidet sich zwischen den Besuchertypen.	Teilweise bestätigt
H3: Bounce/ExitRates stärker als reine Seitenanzahl	Niedrige Bounce- und ExitRates treten häufiger bei Käufern auf.	Teilweise bestätigt
H4: Längere Verweildauer erhöht Kaufwahrscheinlichkeit	Käufer verbringen durchschnittlich mehr Zeit auf Produktseiten.	Teilweise bestätigt

Prinzip:

Hypothesen werden nicht isoliert bewertet, sondern mit EDA, Modellbewertung und Feature Importance zusammengeführt.

ML-MODELL BEWERTUNG & STABILITÄT



MACHIN LEARNING: VOR DER KAUFABSICHT ZUR ZIELGRUPPE



Warum Machine Learning?

- Kaufverhalten ist komplex und nicht direkt sichtbar
- Ziel: Kaufwahrscheinlichkeit frühzeitig erkennen
- Grundlage für datengetriebenes Retargeting

Unser Ansatz

- Vergleich mehrerer ML-Modelle
- Auswahl des leistungsstärksten Modells
- Berechnung einer Kaufwahrscheinlichkeit pro Session
- Segmentierung in niedrig, mittel und hoch

Modellvergleich

- Random Forest
- Decision Tree
- Logistic Regression
- Naive Bayes
- Gradient Boosted Trees

MODELLVERGLEICH UND MODELLAUSWAHL

Auswahlkriterien

- Ungleichgewicht der Klassen berücksichtigt
- Fokus auf F1-Score und ROC-AUC
- Vergleich von Accuracy, Precision und Recall

Model	Accuracy	F1 ▼	Precision	Recall	Kappa
Random Forest	90,30 %	0,66	0,73	0,60	0,60
Decision Tree	90,00 %	0,65	0,71	0,61	0,60
Gradient Boosted Trees	90,10 %	0,65	0,71	0,60	0,60
Naive Bayes	83,10 %	0,55	0,47	0,65	0,45
Logistic Regression	88,20 %	0,50	0,73	0,38	0,44

Gewähltes Modell

Random Forest

0,923

ROC-AUC


65,7 %

F1-Score(Kauf)

- Beste Gesamtleistung im Vergleich
- Stabil und leistungsstark
- Interpretierbar durch Feature Importance

FEATURE IMPORTANCE:

Was beeinflusst die Kaufwahrscheinlichkeit am stärksten?



Top-3 Faktoren

1. PageValues

2. TrafficType


3. ExitRates

Bestätigte Hypothesen


- ✓ H1: Hoher Page Value → höhere Kaufwahrscheinlichkeit
- ✓ H3: Exit Rate als starker Prädiktor
- ✓ H4: Längere Produktinteraktion erhöht Kaufchance
- H2: Im Modell nicht als Top-Faktor bestätigt
- Bounce Rate mit geringerem Einfluss

KUNDENSEGMENTIERUNG FÜR GEZIELTES RETARGETING (US-02)

Customer Segment Distribution




Actual Conversion Rate by Segment



Retargeting-Fokus

- 2,6 Tsd. Sessions mit mittlerer oder hoher Kaufwahrscheinlichkeit identifiziert
- Deutlicher Zusammenhang zwischen Segment und tatsächlichem Kaufverhalten
- Zielgruppen können direkt für Marketing- und Retargeting-Maßnahmen genutzt werden

BUSINESS OUTPUT



Visualisierungen durch KPIs



Conversion Rate: 15,47 %



Avg Page Value: 5,89



Total Purchases: 1,9 Tsd.




AUC (aus ML-Modell): 92,3%

BUSINESS OUTPUT: KUNDENSEGMENTIERUNG FÜR US-02

Scoring-Ergebnisse werden in verwertbare Zielgruppen übersetzt


- 1 Segment 1: Hohe Kaufwahrscheinlichkeit
- 2 Segment 2: mittlere Kaufwahrscheinlichkeit
- 3 Segment 3: niedrige Kaufwahrscheinlichkeit



Retargeting-Fokus

Mittlere und hohe Kaufwahrscheinlichkeit ohne Kaufabschluss werden als Zielgruppen exportiert.


BUSINESS OUTPUT: WICHTIGSTE KAUFENTSCHEIDUNGSTREIBER



Handlungsempfehlungen aus EDA und dem ML-Modell:

Aus Analyseergebnissen werden konkrete Maßnahmen

- 1 Fokus auf Nutzer mit mittlerer bis hoher Kaufwahrscheinlichkeit**
Marketingaktivitäten gezielt auf Nutzer mit mittlerer bis hoher Kaufwahrscheinlichkeit aus, um das größte Potenzial für Konversionen zu erschließen.
- 2 Datengetriebenes Retargeting als Kernstrategie**
Datengestützte Retargeting-Kampagnen sind genutzt, um interessierte Nutzer automatisiert erneut anzusprechen und Kaufabbrüche konsequent zu reduzieren.
- 3 UX- und Funnel-Optimierung basierend auf Schlüsselfaktoren**
Optimierung der Produktseiten und Nutzerführung gezielt anhand der Schlüsselfaktoren, um die Kundeninteraktion zu vertiefen und die Kaufbereitschaft zu erhöhen.



HANDLUNGSEMPFEHLUNGEN AUS EDA UND DEM ML-MODELL

Aus Analyseergebnissen werden konkrete Maßnahmen

4

Optimierung der Traffic-Quellen

Priorisierung im Performance-Marketing gezielt die Kanäle, die nachweislich die höchste Kaufwahrscheinlichkeit generieren.

5

Saisonale Optimierung der Marketingbudgets

Verteilung des Marketingbudgets flexibel und verstärkt auf Monate mit hoher Conversion Rate, um den ROI zu maximieren.

6

Regelmäßige Modellvalidierung und Monitoring

Überwachung und kalibrierung des Vorhersagemodells kontinuierlich, um bei neuen Daten eine langfristige Stabilität und Genauigkeit sicherzustellen.

FAZIT

Die User Storys des ersten Sprints sind fachlich abgedeckt

KERNAUSSAGE

Das Projekt beantwortet die Frage „Wurde der Kauf abgeschlossen?“ durch ein bewertetes Klassifikationsmodell und überführt die Ergebnisse in Business-Zielgruppen.

Erreichte Mehrwerte

Vorhersage der Kaufwahrscheinlichkeit (US-01)

Export relevanter Retargeting-Zielgruppen (US-02)

Identifikation der wichtigsten Einflussfaktoren (US-05)

VIELEN DANK FÜR IHRE AUFMERKSAMKEIT.

FRAGEN?

Wir freuen uns auf Ihre Rückmeldungen und stehen für Fragen zum Projekt und zur Methodik gerne zur Verfügung.