

PROJEKTbeschreibung

Online Shoppers' Purchasing Intention

Prognose der Kaufabsicht im E-Commerce

Gruppenprojekt

Ausgearbeitet von:

Marzieh Vatandoostkamali
Nataliia Melnytska
Annick Constance Demgne Tchuenkam
Hiba Ben Rhouma

JUNI 2026

1. Einleitung und Ist-Analyse

1.1 Ausgangssituation und Hintergrund

Der Datensatz stammt aus dem **UCI Machine Learning Repository** und wurde von Sakar et al. (2018/2019) im Kontext der Forschung zur Kaufentscheidungsvorhersage im E-Commerce erhoben. Er repräsentiert eine reale Online-Shopping-Plattform (Branche: Allgemeiner Einzelhandel) über einen Zeitraum von einem Jahr.

Die Kernfrage lautet: Welche Verhaltenssignale einer Web-Session lassen eine Kaufabsicht (Revenue = TRUE) erkennen?

Im E-Commerce ist die durchschnittliche Konversion Rate typischerweise gering. Im vorliegenden Datensatz liegt sie bei ca. 15,5 %, was dem Branchendurchschnitt entspricht. Das bedeutet: Rund 85 % aller Sitzungen führen zu keinem Kauf, obwohl die Nutzerinnen und Nutzer die Website aktiv besuchen. Hier liegt ein erhebliches Optimierungspotenzial für gezielte Marketing- und Personalisierungsmaßnahmen.

1.2 Datenquellen und Datenprozesse

Die Daten wurden mittels Web-Analytics-Tracking erhoben. Jede Zeile repräsentiert eine abgeschlossene Browser-Session eines Nutzers. Die Datenerfassung umfasst:

- **Session-Verhaltensdaten** (ProductRelated, ProductRelated_Duration, Bounce/Exit-Raten) — erhoben via Webserver-Logs / JavaScript-Tracking
- **Page-Value-Score** — berechnet über Google Analytics Attribution
- **Zielvariable** Revenue (TRUE/FALSE) — aus der Transaktionsdatenbank

Hinweis zur Datenstruktur: Der vorliegende Datensatz liegt als CSV-Datei vor. Er enthält die zuvor in Echtzeit berechneten und anschließend gespeicherten Werte als statische Momentaufnahme.

Datenprozess:

- Extraktion der Rohdaten aus den Web-Analytics-Logs der E-Commerce-Plattform.
- Bereitstellung als strukturierte CSV-Datei (kein Echtzeit-Stream)

1.3 Erläuterung der Daten und EDA

Datenbeschreibung

Der Datensatz enthält **12.330 Sessions** mit 18 Merkmalen (10 numerisch, 6 kategorisch, 2 boolesch). Nachfolgend eine Übersicht aller Features:

Merkmal	Beschreibung	Datentype
Administrative	Anzahl besuchter Admin-Seiten pro Sitzung	Numerische
Administrative_Duration	Verweildauer auf Admin-Seiten (Sekunden)	Numerische
Informational	Anzahl besuchter Info-Seiten	Numerische
Informational_Duration	Verweildauer auf Info-Seiten (Sekunden)	Numerische
ProductRelated	Anzahl besuchter Produktseiten	Numerische
ProductRelated_Duration	Verweildauer auf Produktseiten (Sekunden)	Numerische
BounceRates	Absprungrate (Anteil Einzel-Seitenbesuche)	Numerische
ExitRates	Austrittsrage der zuletzt besuchten Seite	Numerische
PageValues	Durchschn. Seitenwert vor Transaktionsseite	Numerische
SpecialDay	Naehe zu einem speziellen Tag (0-1 Skala)	Numerische
Month	Monat der Sitzung (Feb-Dez)	Kategorische
OperatingSystems	Kodiertes Betriebssystem des Nutzers	Kategorische
Browser	Kodierter Browser des Nutzers	Kategorische
Region	Geografische Region (kodiert, 1-9)	Kategorische
TrafficType	Verkehrsquelle (kodiert, 1-20)	Kategorische
VisitorType	Besuchertyp: New, Returning, Other	Kategorische
Weekend	Boolescher Wert: Wochenendbesuch	Boolescher
Revenue (Zielvariable)	Boolescher Wert: Kauf abgeschlossen	Boolescher

Datenqualität

Die Datenqualität ist insgesamt als gut zu bewerten:

- Keine fehlenden Werte (0 NaN in allen 18 Spalten)
- Keine Duplikate festgestellt (aber 125 vollständig identische Datensätze gefunden)
- Korrekte Datentypen: numerisch, kategorisch, boolesch
- Klasse ist unbalanciert: 84,5 % kein Kauf vs. 15,5 %
- Keine Daten vorliegen für den Monat April und Januar

Da keine eindeutige Sitzungs-ID vorhanden ist, kann nicht sicher festgestellt werden, ob es sich um technische Duplikate oder um tatsächlich identische Besuchersitzungen handelt.

Zentrale EDA-Ergebnisse

Konversion Rate nach Monat:

Monat	Sitzungen	Konversion Rate %
Februar	471,01	1,63
Mars	812,28	10,07
May	981,89	10,85
June	1213,37	10,07
Juli	1217,60	15,28
August	1272,65	17,55
September	1253,38	19,2
October	1116,97	20,95
November	1758,39	25,35
Dezember	1111,47	12,51

Konversion Rate nach Besuchertyp:

Besuchertyp	Anzahl	Conversion Rate
New Visitor	1.694	24,9 %
Other	85	18,8 %
Returning Visitor	10.551	13,9 %

Verhaltensunterschiede zwischen Käufer und Nicht-Käufer:

Merkmal	Kein Kauf	Kauf	Faktor
PageValues (Ø)	1,98	27,26	13,8x
ProductRelated (Ø)	28,7	48,2	1,7x
BounceRates (Ø)	2,5%	0,5%	0,2x
ExitRates (Ø)	4,7%	2,0%	0,4x
Prod. Duration (Ø, Sek.)	1.070	1.876	1,8x

Weitere Befunde:

- PageValues ist das stärkste Einzelmerkmal und korreliert mit der Zielvariable ‚Revenue‘ ($r = 0,49$).
- Eine starke Klassenunbalance (85/15) erfordert angepasste Modellmetriken (Precision, Recall, F1-Score und ROC-AUC) berücksichtigt.

2. Backlog und Projektziele

2.1 User Storys und Potenziale

US-ID	User Story
US-01	Als E-Commerce-Manager möchte ich während einer laufenden Web-Session automatisch die Kaufwahrscheinlichkeit des Besuchers prognostizieren, damit Marketingmaßnahmen gezielter eingesetzt werden können.
US-02	Als Performance-Marketing-Spezialistin möchte ich nach Ablauf eines Tages einen automatisierten Export aller Sessions erhalten, die eine Mittlere Kaufabsicht zeigten, aber ohne Kauf abgebrochen sind, damit ich diese exakte Zielgruppe über Retargeting-Kampagnen (z. B. Google/Meta Ads) kosteneffizient wieder ansprechen kann.
US-03	Als IT-Administrator werde ich den Einfluss der technischen Parameter auf die Performance analysieren damit wir technische Fehler schneller identifizieren und beheben können.
US-04	Als Marketing-Analyst werde ich den Einfluss von saisonalen Faktoren (Monate) auf die Konversion-Rate auswerten damit ich das Werbebudget in hoch performanten Monaten gezielter allokalieren kann.
US-05	Als Data Scientist möchte ich ein erklärbares ML-Modell trainieren, das die wichtigsten Einflussfaktoren aufzeigt, damit die Website und Marketingmaßnahmen optimiert werden können

2.2 Bewertung und Priorisierung (MoSCoW / Low Hanging Fruits)

US-ID	Aufwand	Ertrag	Priorität
US-01	Mittel	Sehr hoch	MUST (Sprint 1)
US-05	Mittel	Sehr hoch	MUST (Sprint 1)
US-02	Niedrig	hoch	MUST (Sprint 1)
US-04	Hoch	Sehr hoch	SHOULD (Sprint 2)
US-03	Hoch	Mittel	COULD (Sprint 3)

2.3 Ausgewählte Projektziele für Sprint 1

- Entwicklung eines binären Klassifikationsmodells zur Vorhersage der Kaufwahrscheinlichkeit (US-01)
- Definition von Klassifizierungsregeln zur Einteilung von Sessions in mittlere und hohe Kaufabsicht ohne Kauf sowie Export der relevanten Session-Daten (US-02)
- Durchführung einer explorativen Datenanalyse und Bestimmung der Feature-Wichtigkeit als Grundlage für UX-Empfehlungen (US-05)

3. Projektausarbeitung – Hypothesen

3.1 Hypothesen und Zuordnung zu User Storys

Folgende Hypothesen werden im ersten Sprint überprüft:

Hypothese	Beschreibung	US-Zuordnung
H1	Besucher mit einem überdurchschnittlichen Page Value haben eine höhere Kaufwahrscheinlichkeit als Besucher mit einem unterdurchschnittlichen Page Value.	US-01, US-05
H2	Der Besuchertyp (neu oder wiederkehrend) beeinflusst die Kaufwahrscheinlichkeit eines Besuchers.	US-01, US-05, US-04
H3	Niedrige BounceRate und ExitRates sind stärkere Prädiktoren für einen Kaufabschluss als die Anzahl besuchter Seiten.	US-01, US-05, US-02, US-04
H4	Eine längere Verweildauer auf der Website erhöht die Wahrscheinlichkeit eines Kaufs.	US-01

4. Projekt Metriken

4.1 Messung von Fortschritt und Erfolg

Sowohl der Projekterfolg als auch die Qualität der Analyseergebnisse werden anhand definierter Metriken bewertet. Dabei kommt das ausgewählte Modell „Random Forest“ zum Einsatz:

Metrik	Beschreibung	Zielwert	Ergebnis	Status
Accuracy	Anteil aller korrekt klassifizierten Datensätze	$\geq 0,88$	90,3 %	✓
F1-Score (Klasse: Kauf)	Hauptmetrik für Modellqualität	$\geq 0,60$	0,657	✓
Precision (Klasse: Kauf)	Anteil korrekt vorhergesagter Käufer	$\geq 0,65$	0,727	✓
Recall (Klasse: Kauf)	Anteil erkannter Käufer unter allen Käufern	$\geq 0,55$	$\approx 0,60$	✓
OC-AUC	Güte der Wahrscheinlichkeitsschätzung:	$\geq 0,88$	0,923	✓
Hypothesenverifizierung	Mind. 4 von 4 Hypothesen bestätigt oder widerlegt	4	4	✓
Sprint-Velocity	Alle Sprint-1-Tasks abgeschlossen innerhalb Time box	33	54	⚠ / +63%



Der zusätzliche Aufwand entstand durch die Durchführung der Cross-Validation, Feature Importance-Analyse sowie die Entwicklung zusätzlicher Business-Outputs.

4.2 Definition Done (DoD)

User Story	Definition of Done
US-01: ML-Modell	Entwicklung und Evaluation eines binären Random-Forest-Klassifikationsmodells zur Vorhersage der Kaufwahrscheinlichkeit von Web-Sessions. Das Modell wird mittels Testdaten oder Cross-Validation evaluiert und erreicht einen F1-Score $\geq 0,67$.
US-02: Zielgruppe exakt getroffen	Implementierung eines produktiven Scoring-Workflows zur Klassifikation von Live-Web-Sessions mittels eines geladenen Random-Forest-Modells (Model Reader). Die Sessions werden anhand definierter Schwellenwerte der Kaufwahrscheinlichkeit in folgende Klassen eingeteilt: - Mittlere Kaufabsicht ohne Kauf (z. B. $0.2 \leq p < 0.4$ & kein Kauf) - Hohe Kaufabsicht ohne Kauf ($p \geq 0.4$ & kein Kauf) Die klassifizierten Sessions werden als strukturierter Export (z. B. CSV oder Datenbank-Output) für Marketing- und Retargeting-Zwecke bereitgestellt.“
US-05: Business Insights fürs Marketing	Durchführung einer explorativen Datenanalyse (EDA) zur Identifikation von Verhaltensmustern im E-Commerce-Datensatz. Zusätzlich wird eine Feature-Importance-Analyse (Tree-based, Random Forest) durchgeführt. Die Ergebnisse werden genutzt, um konkrete UX- und Marketing-Empfehlungen abzuleiten (z. B. Optimierung von Seitenwert, Bounce Rate und Exit Rate). Die wichtigsten Einflussfaktoren werden in einem strukturierten Report dokumentiert

5. Planung des ersten Sprints

5.1 Aufgabenpakete und Aufwandschätzung

Task-ID	Aufgabe	Aufwand (h)	Abhängigkeit
T-01	Datenladen und erste EDA (Shape, Datentypen, Fehlende Werte)	2	-
T-02	Vertiefende EDA: Konversion nach Monat, Besuchertyp, Merkmalskorrelationen	4	T-01
T-03	Feature Engineering: Encoding kategorischer Merkmale	2	T-02
T-04	Baseline-Modell: Ausgangshypothese	1	T-03
T-05	Hauptmodell: Random Forest Classifier mit Cross-Validation	5	T-04
T-06	Modell-Evaluation: Confusion Matrix, F1, ROC-AUC, Feature Importance	4	T-05
T-07	Modellanwendung und Prädiktion der Kaufwahrscheinlichkeit	3	T-05, T-06
T-08	Hypothesen überprüfen und dokumentieren	5	T-02
T-09	Dashboard-Entwicklung (Tableau / Power-Bi): Konversion-KPIs	4	T-02, T-07
T-10	Sprint-Dokumentation und Projektbericht finalisieren	3	T-02, T-07, T-08

6. Zusammenfassung der Ergebnisse

6.1 Verifizierung der Hypothesen

Hypothese	Ergebnis	Begründung
H1: Nutzer mit überdurchschnittlichem Page Value haben eine höhere Kaufwahrscheinlichkeit.	Bestätigt	Es besteht eine deutliche positive Korrelation ($r = 0,49$) zwischen Page Value und Kaufwahrscheinlichkeit. Zudem weist die Klasse „Kauf“ einen deutlich höheren durchschnittlichen Page Value auf. Page Value ist der wichtigste Prädiktor im Modell.
H2: Der Besuchertyp (neu oder wiederkehrend) beeinflusst die Kaufwahrscheinlichkeit eines Besuchers.	Teilweise bestätigt	In der explorativen Datenanalyse zeigen neue Besucher eine höhere Conversion Rate. In der Modellierung besitzt der Besuchertyp jedoch eine geringere Vorhersagekraft im Vergleich zu stärkeren Features wie Page Value oder Produktinteraktionen.
H3: Niedrige BounceRates und ExitRates sind stärkere Prädiktoren für einen Kaufabschluss als die Anzahl besuchter Seiten.	Teilweise bestätigt	Niedrige BounceRates und ExitRates zeigen einen deutlichen Zusammenhang mit Kaufabschlüssen und unterscheiden Käufer stärker von Nicht-Käufern als die reine Anzahl besuchter Seiten. Der wichtigste Einzelprädiktor im Modell bleibt jedoch PageValues.
H4: Eine längere Verweildauer auf der Website erhöht die Wahrscheinlichkeit eines Kaufs.	Teilweise bestätigt	Käufer verbringen im Durchschnitt deutlich mehr Zeit auf Produktseiten (1.876 Sek. vs. 1.070 Sek.). Die Verweildauer allein ist jedoch kein ausreichend starker Prädiktor für einen Kaufabschluss.

6.2 Überprüfung der Definition of Done

User Story	Definition of Done
US-01: ML-Modell	Modell trainiert, evaluiert ($F1 \geq 0,67$), Feature Importance dokumentiert, Code versioniert
US-02: Zielgruppe exakt getroffen	Die Schwellenwerte zur Segmentierung der Kaufwahrscheinlichkeit basieren auf quantilenbasierter Analyse der Modellverteilung und nicht auf festen, willkürlichen Grenzen.
US-05: Business Insights fürs Marketing	Feature Importance Analyse: Tree-Based Feature Importance

Handlungsempfehlungen aus EDA und dem ML-Modell:

Die Analyse zeigt, dass die Kaufwahrscheinlichkeit maßgeblich durch das Nutzerverhalten im Session-Verlauf beeinflusst wird. Insbesondere das Random-Forest-Modell sowie die Feature-Importance-Analyse identifizieren folgende zentrale Einflussfaktoren auf die Kaufentscheidung: Page Value, Traffic Type, Exit Rate, Month sowie ProductRelated_Duration. Diese Variablen bilden die wichtigste Grundlage für die folgenden, datengetriebenen Handlungsempfehlungen zur Konversion-Optimierung und Umsatzsteigerung.

1. Fokus auf Nutzer mit mittlerer bis hoher Kaufwahrscheinlichkeit

Marketingmaßnahmen sollten gezielt auf Nutzer mit mittlerer bis hoher Kaufwahrscheinlichkeit ausgerichtet werden. Diese Gruppe stellt das größte skalierbare Potenzial dar, da sie bereits ein signifikantes Kaufinteresse zeigt, den Kauf jedoch noch nicht abgeschlossen hat.

2. Datengetriebenes Retargeting als Kernstrategie

Nutzer aus den relevanten Wahrscheinlichkeitssegmenten sollten automatisiert in Retargeting-Kampagnen (z. B. Google Ads oder Meta Ads) überführt werden. Ziel ist es, potenzielle Käufer erneut anzusprechen und Kaufabbrüche systematisch zu reduzieren sowie die Konversion Rate zu steigern.

3. UX- und Funnel-Optimierung basierend auf Schlüsselfaktoren

Basierend auf den wichtigsten Einflussfaktoren (insbesondere Page Value und ProductRelated_Duration) sollten Produktseiten, Inhalte und Nutzerführung optimiert werden, um die Interaktion zu erhöhen und die Kaufwahrscheinlichkeit zu steigern.

4. Optimierung der Traffic-Quellen

Traffic Type als wichtiger Einflussfaktor zeigt, dass unterschiedliche Kanäle unterschiedlich starke Kaufwahrscheinlichkeiten erzeugen. Daher sollten besonders performante Traffic-Quellen priorisiert und gezielt im Performance-Marketing ausgebaut werden.

5. Saisonale Optimierung der Marketingbudgets

Die Conversion Rate variiert je nach Monat. Daher sollten Marketingbudgets flexibel gesteuert und gezielt in Monaten mit überdurchschnittlicher Conversion Rate eingesetzt werden, um den ROI zu maximieren.

6. Regelmäßige Modellvalidierung und Monitoring

Die definierten Schwellenwerte für die Kaufwahrscheinlichkeit sollten kontinuierlich überprüft und anhand neuer Daten (z. B. Quantil-basierte Segmentierung oder Modellverteilung) angepasst werden. Zusätzlich ist ein kontinuierliches Monitoring notwendig, um Datendrift frühzeitig zu erkennen und die Modellstabilität langfristig sicherzustellen.

6.3 Ausblick auf nächste Schritte

- ❖ Sprint 2: Analyse des Einflusses saisonaler Faktoren (Monate) auf die Conversion-Rate. Der Monat Januar ist im Datensatz nicht enthalten, weshalb eine saisonale Extrapolation für diesen Zeitraum nicht validiert ist und entsprechend kritisch betrachtet werden muss.
- ❖ Sprint 2: Entwicklung einer Absprungsprognose (US-04) sowie Integration eines A/B-Testing-Ansatzes zur Validierung von Marketingmaßnahmen.
- ❖ Sprint 3: Analyse des Einflusses technischer Parameter auf die Modell- und Systemperformance, um technische Fehlerquellen frühzeitig zu identifizieren und zu beheben.
- ❖ Sprint 3: Implementierung einer Echtzeit-Scoring-API zur Live-Klassifikation der Kaufwahrscheinlichkeit (US-01) für Web-Sessions.
- ❖ Langfristig: Aufbau eines Modell-Monitoring-Systems inklusive Datendrift-Erkennung sowie regelmäßiges Re-Training zur Sicherstellung der Modellstabilität und -qualität.

7. Ergänzungen zur Dokumentation

7.1 Projektstruktur

Empfohlene Verzeichnisstruktur für das Projekt:

Verzeichnis / Datei	Inhalt
—— 01_data_import/	Datenimport
—— 02_data_quality/	Prüfung der Datenqualität
—— 02_1_data_cleaning/	Datenbereinigung
—— 02_2_error_handling/	Fehler- und Validierungsmechanismen
—— 03_eda/	Explorative Datenanalyse
—— 04_hypothesis_testing/	Erste Hypothesenprüfung
—— 05_feature_engineering/	Data Encoding / Feature Engineering
—— 06_modeling/	Modellierung und Modellbewertung
—— 06_1_training/	Machine Learning Training
—— 06_2_evaluation/	Modellbewertung
—— 07_stability_test/	Stabilitätstest / Robustheit
—— 08_feature_importance/	Feature Importance Analyse
—— 09_business_value/	Geschäftlicher Nutzen / Ableitungen
—— 09_1_database_simulation/	⚠ Simulation Datenbankankbindung
—— 09_2_user_story_validation/	Prüfung der User Stories
—— 09_3_outputs/	Daten exportieren
dashboard/powerbi/	Power BI Dashboards und Visualisierungen
reports/pdf/	Abschlussbericht (PDF)
reports/ppt/	Präsentation (PowerPoint)

7.2 Reproduzierbarkeit

- **KNIME:** Version 5.8.3 wird für die gesamte Datenverarbeitung, Modellierung und Auswertung verwendet.
- **Power BI:** Wird für die Visualisierung und das Reporting der Ergebnisse eingesetzt.
- **Datenmanagement:** Der Originaldatensatz wird unverändert im Verzeichnis data/raw/ gespeichert. Alle Verarbeitungsschritte erfolgen nachvollziehbar und versionierbar in data/processed/, sodass eine vollständige Reproduzierbarkeit der Datenpipeline gewährleistet ist.
- **Dokumentation:** Die Projektbeschreibung wird in *Arial Nova Light*, *Schriftgröße 11* erstellt; Überschriften werden in Größe 18 (Titel) und 14 (Untertitel) formatiert.

7.3 Glossar

Begriff	Definition
Conversion Rate	Anteil der Sitzungen, die zu einem Kauf führen
Bounce Rate	Anteil der Sitzungen, die nach Besuch einer einzigen Seite abgebrochen werden
PageValues	Durchschnittlicher Geldwert einer Seite, bevor eine Transaktionsseite aufgerufen wird.
F1-Score	Harmonisches Mittel aus Precision und Recall; wichtig bei unbalancierten Klassen
SMOTE	Synthetic Minority Over-sampling Technique: künstliche Erhöhung der Minderheitsklasse
SHAP	SHapley Additive Explanation: Methode zur Erklärung von ML-Modell-Entscheidungen
ROC-AUC	Fläche unter der Receiver Operating Charakteristik Kurve; Guetemas für Klassifikatoren

NB: Sie finden das Dokument „Technische Beschreibung des ersten Sprints anhand des Machine Learning Canvas“ als separaten Download zusammen mit diesem Dokument